

AI塔羅

Arcana Oraculum

一個把 **OpenAI-compatible LLM**、**LLM-as-Guardrail**、**SDXL 圖像生成** 與即時管理面板整合在一起的互動式塔羅網站。

TEAM MEMBERS

111550029 蔡奕庠
110550048 許維也
109950026 李明謙
112652030 呂泰廷
0816132 蔡欣龍
112550026 林均濤

OPENING

從一個問題開始

The screenshot shows a web application titled "ARCANA ORACULUM" with a subtitle "古老的牌中，藏著你尚未說出口的問題" (In ancient cards, hidden are the questions you have not yet said out loud). The interface includes a navigation bar with "HOME" and "HOW TO USE" links. The main form contains a "求問者的生日" (User's Birthday) field with the value "1996/05/27", a "你想問什麼?" (What do you want to ask?) field with the example question "例：我最近的工作機會該不該接?" (Example: Should I take the job opportunity I recently encountered?), and a "開始占卜" (Start Divination) button. The footer text reads "ARCANA ORACULUM · POWERED BY GROQ · LLM: LLAMA 3.1-8B 參閱此" (ARCANA ORACULUM · POWERED BY GROQ · LLM: LLAMA 3.1-8B See this).

輸入

使用者留下生日與想詢問的問題，像是在進入一場線上占卜。

判斷

系統先分辨這個問題是否適合被塔羅回應。

生成

通過後，文字解讀與牌面圖像分成兩條路徑產生。

生成式占卜的三個挑戰

個人化

塔羅不只是固定牌義查表，回應要能讀進使用者的問題、生日與三張牌的位置。

安全邊界


輸入可能包含 Prompt Injection、越獄、暴力、自傷訊號或離題需求，需要先被分類。

等待體驗

圖像生成比文字慢，前端必須把等待轉化成可理解的牌面顯化流程。

目標不是做一個會聊天的塔羅師，而是把生成式 AI 放進有邊界、可觀察、可替換的產品流程。

一個請求如何穿過系統



FastAPI • async

uv • Python 3.13

OpenAI-compatible API

Streamable HTTP MCP

Vanilla JS + Lucide

JSONL Log

/api/draw 的決策路徑

後端順序

1. 收到使用者的生日、問題與進階設定。
2. 先送審查官，拿到八類安全標籤並寫進紀錄。
3. 依審查官提供的結果，有以下三種路徑：
 - A. 不安全 → 封印頁
 - B. 自殺 (crisis) → 求助資源
 - C. 放行
4. 放行後抽三張 Major Arcana，交給占卜師解讀，並在背景啟動生圖。

```
classification = guard_classify(  
    question,  
    guard_client,  
    model=guard_model,  
)  
attack_log.record(question, classification, ip, reading_mod  
  
if not classification["safe"]:  
    return jsonify({"blocked": True, ...})  
  
if classification["category"] == "crisis":  
    return jsonify({"crisis": True, ...})  
  
drawn = random.sample(MAJOR_ARCANA, 3)
```

LLM-as-Guardrail：八類輸入分類

clean

正常塔羅問題

crisis

自傷或自殺訊號

prompt_injection

要求忽略規則、輸出 System Prompt

jailbreak

Admin / Developer Mode

nsfw

色情或性暗示

violence

武器或傷害他人

off_topic

寫 Code、數學、翻譯等離題

minor_safety

未成年與高風險主題

封印：把拒答做成產品語言



封印狀態保留三件事

- **分類 Label**：讓團隊知道被擋的原因。
- **原因 Reason**：讓使用者理解界線，而不是只看到錯誤碼。
- **紀錄 Log**：記錄在日誌當中，但不紀錄 API Key。

危機訊號不封鎖，改成把牌放下

為什麼 `crisis` 仍然是 `safe: true` ？

- 自傷或自殺訊號不適合被冷冰冰地拒絕。
- 系統停止占卜流程，改給台灣求助資源。
- 這是 Routing，不是一般內容封鎖。



解讀模型吃的是結構化上下文

Prompt Inputs

- 求問者生日
- 使用者問題
- 三張牌的位置、中英文名、**正位/逆位** 與對應關鍵字
- 可由進階模式覆寫的 System Prompt（內含區分正逆位的指示）

以三牌陣抽出的牌（含正逆位）：

- 第 1 張【過去】：愚者（The Fool）【正位】
 - 關鍵字：新開始、純真、冒險、自由
- 第 2 張【現在】：高塔（The Tower）【逆位】
 - 關鍵字：避免災難、延後變化、害怕改變
- 第 3 張【未來】：星星（The Star）【正位】
 - 關鍵字：希望、靈感、平靜、療癒

解讀時務必明確區分每張牌是正位還是逆位。

Lazy-flip：圖好，牌才翻



前端流程

1. 後端先回傳 `job_id`、三張牌與文字解讀。
2. 前端顯示牌背與占卜師獨白。
3. 每 1.5 秒呼叫 `/api/image/{job}/{idx}`。
4. 某張圖完成，才翻開那一張牌。

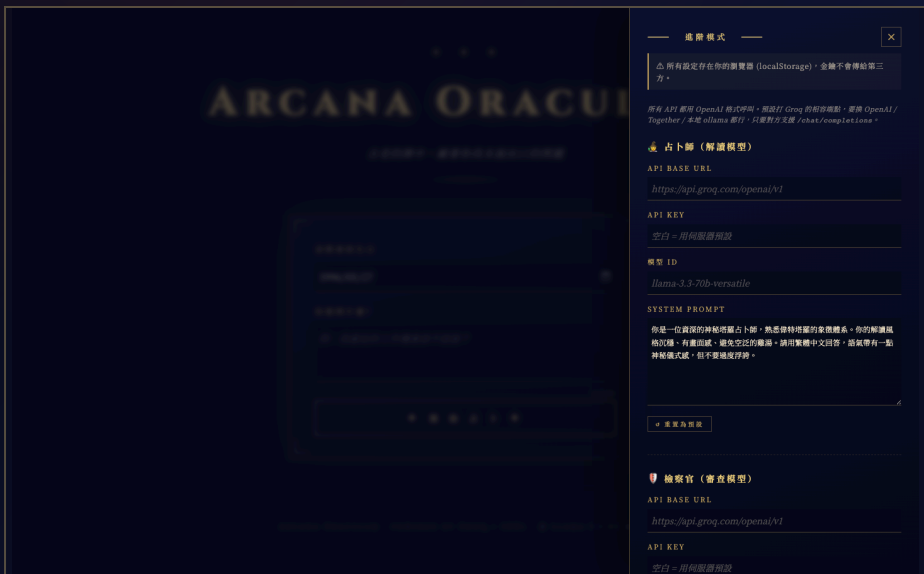
每張牌都有自己的圖像語彙

tarot/cards.py

- 22 張 Major Arcana 。
- 每張牌有中英文名、關鍵字與 `imagery` 。
- `STYLE_PREFIX` 統一生成的圖片美術風格，金色邊框與神祕氛圍。
- `NEGATIVE_PROMPT` 控制 SFW 與畫質限制。

```
STYLE_PREFIX = (  
    "masterpiece, best quality, "  
    "art nouveau, alphonse mucha style, "  
    "ornate golden art deco border, "  
    "sfw, safe, fully clothed, ..."  
)  
  
def build_sdxl_prompt(card):  
    return STYLE_PREFIX + card["imagery"], NEGATIVE_PROMPT
```

模型與後端可以在介面切換



可調參數 (localStorage，無需重啟)

- **Reading Model** : Base URL、API Key、Model ID、System Prompt。
- **Guard Model** : Base URL、API Key、Model ID。
- **三種 Image Backend** :
 1. A1111
 2. OpenAI /images/generations
 3. OpenAI /chat/completions w/ modalities (Nano Banana 等)。
- **MCP 工具** : HTTP URL、Auth Header、逐工具勾選啟用。

三種圖像 backend，同樣的介面

A1111 SDXL

`/sdapi/v1/txt2img`

本地、可控、可掛 Lightning LoRA。

支援 Negative Prompt 與 Checkpoint 切換。

OpenAI `/images/generations`

標準 OpenAI 圖像端點。預設 `gpt-image-1`。

Azure / Together / Fireworks 同 schema。

OpenAI `/chat/completions`
w/ `modalities`

OpenRouter Nano Banana / Gemini 2.5 Flash Image 等。

HTTP MCP：占卜師會自己呼叫工具

流程

1. 使用者在 UI 新增 MCP 伺服器、勾選想開放給占卜師的工具。
2. 後端連線並 **重用 Session**，省下每次的握手成本。
3. 占卜師收到可用工具，**按需要呼叫**，把結果融入解讀。
4. UI 在解讀下方展開顯示每次工具呼叫的 Input / Output。

```
from mcp import ClientSession
from mcp.client.streamable_http import (
    streamablehttp_client,
)

async with streamablehttp_client(
    url, headers={"Authorization": auth},
) as (r, w, _):
    async with ClientSession(r, w) as s:
        await s.initialize()
        tools = (await s.list_tools()).tools
        result = await s.call_tool(name, args)
```

Scalar : 互動式 API 文件

三個出口

- `/scalar` : Scalar 互動瀏覽器
- `/docs` : Swagger UI (FastAPI 預設)
- `/openapi.json` : 規格本體, 給外部 Codegen 使用

```
from scalar_fastapi import get_scalar_api_reference

@app.get("/scalar", include_in_schema=False)
async def scalar_html(request: Request):
    base = str(request.base_url).rstrip("/")
    return get_scalar_api_reference(
        openapi_url=app.openapi_url,
        title=f"{app.title} API",
        dark_mode=True,
        telemetry=False,
        base_server_url=base,
        servers=[{"url": base, "description": "Current host"}
    )
```

哪些資料在哪邊：明確劃分

瀏覽器 localStorage

- 使用者覆寫的 Reading / Guard / Image API Key、URL、Model
- MCP 伺服器 URL + Auth Header
- 系統 Prompt 自訂

隨請求送出，後端絕不寫入磁碟。

後端 .env

- Fallback：預設 LLM key、預設 Model、SDXL URL
- 三種圖像 Backend 各自的 Base URL / Key / Model（含 Cloud）
- `ARCANA_DEFAULT_IMAGE_BACKEND` 決定首次造訪的預選 Backend
- Server 設定：Host / Port / Log Level / Tool-use 上限

填了 Cloud Key 就能做「沒裝 SDXL 也能一鍵 Demo」。

沒填則回到 UI 必須提供 Credentials。

安全不是黑盒：每一次分類都可觀察



JSONL

Append-only 攻擊紀錄，重啟後載回最近 500 筆。

2s

前端每 2 秒拉取狀態。

No Key

Log 不紀錄 API key。

少量 Endpoint 支撐完整流程

GET /

塔羅主畫面與互動入口

GET /api/image/<job>/<idx>

前端 polling 單張卡圖狀態

GET /api/admin/stats

總數、攔截、危機與分類分佈

POST /api/admin/clear

清空觀測資料

GET /health

FastAPI 健康檢查（含 SDXL 連線狀態）

POST /api/draw

Guardrail、抽牌、解讀與背景生圖

GET /admin

安全分類與攻擊紀錄面板

GET /api/admin/recent

最近分類紀錄

POST /api/mcp/test

連線 MCP 伺服器並回傳工具列表（前端 test/refresh 共用）

GET /docs

FastAPI 自動產生的 OpenAPI 文件

幾個值得說明的設計取捨

Fail-open

審查模型失敗時放行，避免暫時性 API 問題讓正常問題全部被擋下。

Key Handling

API Key 存在瀏覽器 `localStorage`，只隨請求送到後端，不寫入 JSONL。

Crisis Routing

自傷訊號不走封印，而是顯示專業協助資源，讓產品回應更符合情境。

Prompt Boundary

Guard Prompt 明確把使用者輸入視為待分類資料，降低 Prompt Injection 生效機率。

AI 不是只產生答案，而是進入一個有邊界的體驗

輸入先被理解

問題先經過 Guardrail，再決定是封印、關懷路由或正常解讀。

模型可以替換

Reading、Guard 與 Image Backend 都透過介面設定，不綁死單一供應商。

等待有敘事

文字先出現，牌面等待圖像完成後翻開，讓技術延遲變成互動節奏。

安全可觀察

分類結果、攔截比例與最近紀錄都進入 Admin 面板，方便團隊回看。

TEAM

小組分工

程式開發

- 109950026 李明謙
- 111550029 蔡奕庠

簡報製作

- 110550048 許維也
- 112652030 呂泰廷
- 0816132 蔡欣龍
- 112550026 林均濤

THANK YOU

AI塔羅

Arcana Oraculum

Generative AI + AI Safety + Interactive Web UI